

倪培洹

北京市海淀区中关村东路 95 号, 中国科学院自动化研究所

+86 158 0375 7631 $\diamond$ nipeihuan24@mails.ucas.ac.cn $\diamond$ peihuanni.github.io

教育经历

吉林大学, 学士

2020 年 9 月 – 2024 年 6 月

电子科学与工程学院, 微电子科学与工程

导师: 阎凯歌

CET-4: 603, CET-6: 553

中国科学院大学, 硕士研究生

2024 年 9 月 – 2027 年 6 月

人工智能学院, 人工智能

导师: 程健、李钢

GPA: 3.81

科研经历

第一作者论文

Peihuan Ni, Zitao Mo, Tielong Liu, Hongli Wen, Zeyu Zhu, Minnan Pei, Junwen Si, Weifan Guan, Peisong Wang, Qinghao Hu, Gang Li and Jian Cheng. **APEX: Integer-only Non-linear Function Approximation for Efficient Cross-Modal Inference**. In DATE 2026. (CCF-B, 计算机体系结构顶级会议)

- 发现不同模态模型在量化后的数据分布存在显著差异, 使其对非线性函数近似误差表现出不同敏感性, 而统一保留高精度会导致计算位宽和硬件开销过高。
- 提出统一的整数非线性计算架构, 融合多种常用非线性算子的计算图, 并通过比特级剪枝减少计算位宽, 同时保持模型精度。
- 在语言模型和视觉模型上分别提升最高约 0.7% 和 1.3% 的任务精度, 并在多模态模型上实现近乎无损推理。
- 相较已有方法, 面积降低 1.73–8.71 $\times$, 功耗降低 1.21–10.83 $\times$ 。

Peihuan Ni, Zeyu Zhu, Weifan Guan, Gang Li, Zitao Mo, Tielong Liu, Junwen Si, Qinghao Hu, Peisong Wang and Jian Cheng. **ACE-VLA: Action-Centric Evaluation for Token Pruning in Vision-Language-Action Models**. Submitted to CoRL 2026. (智源 A 类会议, 人工智能顶级会议)

- 指出现有 VLA 剪枝方法主要沿用 VLM 中的文本-视觉注意力评价方式, 未充分利用动作输出中包含的任务阶段和运动语义信息。
- 提出以动作输出为中心的梯度评价指标, 并使用基于运动轨迹的动态 Token 池维护策略降低重要性评估开销。
- 从运动学角度建模机器人的运动趋势, 而非仅依据瞬时运动状态, 实现动态剪枝比例调整。
- 在 $\pi_{0.5}$ 和 π_0 模型上分别提升约 1.4% 和 2.2% 的任务成功率, 并在 OpenVLA-OFT 上取得优于现有基线的综合性能。
- 通过真机实验验证方法在真实场景中的可迁移性, 并提升 VLA 剪枝过程的可解释性。

共同作者论文

Zeyu Zhu, Gang Li, Minnan Pei, Zitao Mo, **Peihuan Ni**, Peisong Wang, Tielong Liu and Jian Cheng. **KL-MoE: A Hierarchical MoE Pruning Framework Exploiting KL Divergence**. In DAC 2026. (CCF-A, 并行与分布计算顶级会议)

Tielong Liu, Zeyu Zhu, Gang Li, Zitao Mo, Chen BAI, Junwen Si, **Peihuan Ni**, Minnan Pei, Peisong Wang, Zhuoran Song, Xiaoyao Liang and Jian Cheng. **FLUTE: A LUT-Based Floating-Point Engine for Efficient LLM Acceleration Exploiting Core-Tail Hierarchical Alignment**. In MICRO 2026. (CCF-A, 计算机体系结构顶级会议)

Junwen Si, Gang Li, Tielong Liu, **Peihuan Ni**, Minnan Pei, Zeyu Zhu, Zitao Mo, Peisong Wang, Zhongfeng Wang and Jian Cheng. **DOLA: A Dataflow Optimization Framework for Efficient Inference of Linear Attention Models on FPGAs**. Submitted to TCAD. (CCF-A, 计算机体系结构顶级期刊)

Zeyu Zhu, Gang Li, Peisong Wang, **Peihuan Ni**, Tielong Liu, Minnan Pei, Junwen Si, Zhuoran Song, Xiaoyao Liang and Jian Cheng. **DALI: A Workload-Aware Offloading Framework for Efficient MoE Inference on Local PCs**. Submitted to ATC 2026. (CCF-A, 并行与分布计算顶级会议)

实习经历

华为技术有限公司，计算产品线

Ascend 950 NPU 大模型推理系统加速

2026 年 7 月 – 2027 年 7 月

- 面向 Ascend 950 NPU 开展大模型推理系统分析与性能优化，重点研究算子调度、片上数据流和计算资源利用率。
- 分析大模型推理过程中 Cube、Vector 及存储层次之间的性能瓶颈，并探索适用于 MoE 和长序列推理的系统级优化方法。

项目经历

VLA 模型量化压缩与 FPGA 端侧部署

项目负责人

- 设计 W4A8 量化方案，其中权重采用 4-bit 量化，激活值和 KV Cache 采用 8-bit 量化，并结合纯整数非线性近似实现近乎无损的端侧推理。
- 实现基于 FP16-INT8 MAC 的量化与反量化融合算子，减少中间数据回写和片外访存，提高激活值的片上驻留比例。
- 复用 FP16-INT8 MAC 完成 RoPE 等算子的计算，并调整部分计算顺序，提高计算单元和片上数据的复用效率。
- 面向 W4A8 混合精度矩阵乘法设计比特串行计算单元，以及支持不同注意力头维度的 KV 重排序模块和 BRAM 到计算阵列的 Crossbar 数据映射。
- 设计统一的纯整数非线性计算单元，在降低硬件面积和功耗的同时支持多类非线性算子，相关成果发表于 DATE 2026。
- 参与 VLIW 编译器设计，负责片上数据流、指令处理器和算子控制模块；通过地址偏移和多种偏移模式，将单次模型推理所需指令数降低 32× 以上。
- 在 GPU 上实现 Bit-Accurate 仿真器，并完成与 Vivado 模块级仿真及 FPGA 整网运行结果的逐级对齐。
- 完成 DMA 访存通路调试、HBM 带宽优化、VHK158 开发板数据通路调试、时序收敛及 PetaLinux 系统制作，实现模型在 FPGA 上的完整部署。

基于 Ascend A5 NPU 的大模型分析与推理优化

项目负责人

- 分析 Ascend 架构中矩阵计算单元与向量计算单元算力不对称导致的性能瓶颈，定位 MoE 推理中的非线性算子、数据搬运和计算资源空闲问题。
- 探索矩阵乘法与非线性计算的细粒度流水和重叠执行方案，以改善 Cube 与 Vector 之间的负载均衡并提升整体硬件利用率。

奖项荣誉

综合荣誉

中国科学院大学三好学生

竞赛获奖

英特尔杯全国大学生电子设计竞赛邀请赛三等奖

全国大学生数学建模竞赛二等奖

中国大学生数学竞赛三等奖

社会服务

WACV、EMNLP、CoRL 审稿人